CICS'26 정보 및 제어 학술대회

양팔 이동 조작 정책의 조작 성능과 언어 지시 추종의 괴리

Dissociation between Manipulation Performance and Language Instruction Following in a Bimanual Mobile Manipulation Policy

김미송*, 김송연*, 최명기*, 김현우†, 조혜경* *한성대학교 AI응용학과 †주식회사 로보시지

연구 배경 및 목적 Background

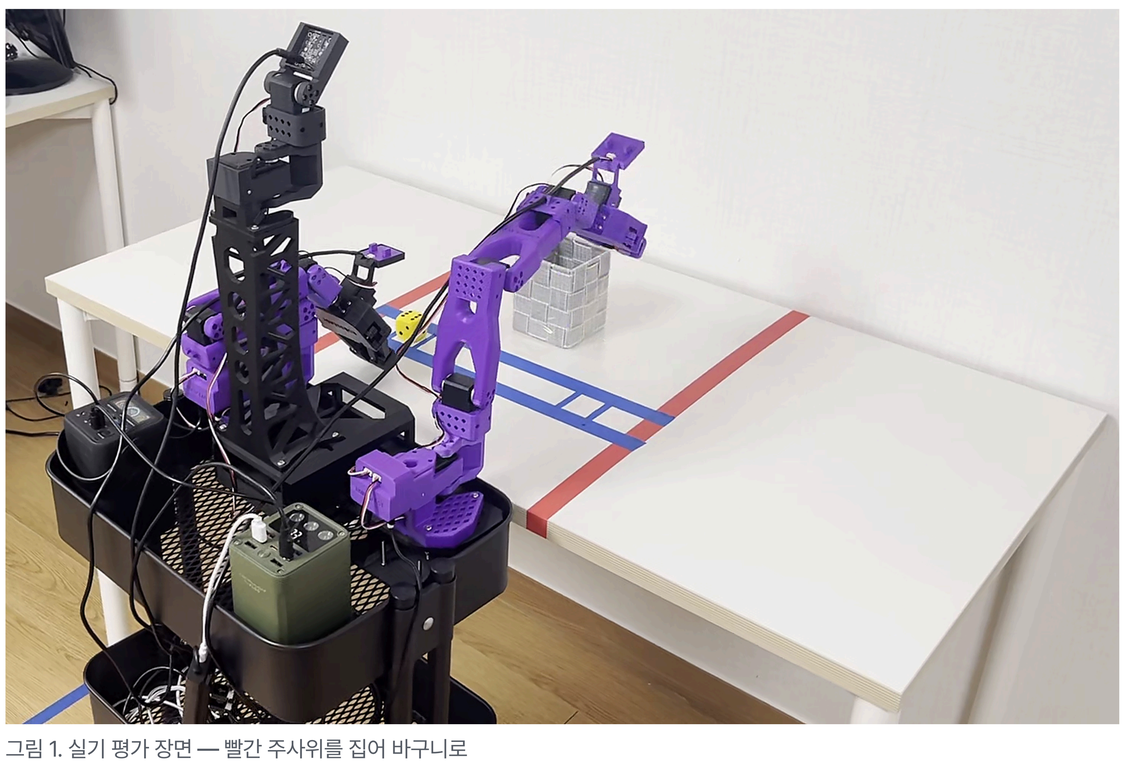


그림 1. 실기 평가 장면 — 빨간 주사위를 집어 바구니로

- 저가형 VLA 평가는 **고정형 단팔** 중심[1] — 이동 베이스 + 양팔 통합 정책 평가는 드묾[2]
- 높은 조작 성공률 ≠ 언어 지시 추종 — 최근 제기되는 문제[3,4]
- 양팔 로봇은 목표 물체에 따라 팔을 골라야 함 → 언어가 행동 결정에 반영되는지 직접 확인 가능

RQ1 **SmolVLA[5]가 ACT[6]보다 높은 조작 성능을 보이는가?**

RQ2 **언어 지시에 따라 올바른 팔을 선택하는가?**

- 추가 분석: 팔 선택 분기 직전 언어·영상·관절 입력을 하나씩 교체 → 정책이 무엇에 반응하는지 확인

시스템 구성 System

- SO-ARM101 양팔 + 3옴니휠 베이스, 카메라 4대
- 행동·관측 상태 15차원 — 양팔 관절 12 + 베이스 속도 3



그림 2. 분산 제어 구조 — 무선은 평균 812 ms 지연으로 관측 갱신 불가 → 모든 평가는 유선(왕복 평균 2.8 ms)·30 Hz 고정

과제 및 실험 설정 Task & Methods

- 좌·우 출발 위치 중 한 곳에서 시작 → 1 m 앞 책상까지 이동
- 빨강·노랑 주사위 중 지시된 색을 그쪽 팔로 집어 바구니에 투입

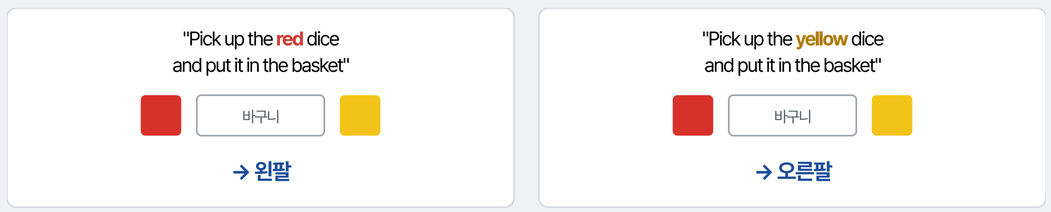


그림 3. 같은 장면이라도 색 단어 하나로 써야 할 팔이 바뀜 — 두 주사위가 늘 함께 있어 영상만으로는 대상 결정 불가 (좌우 배치는 시행마다 바뀜)

데이터 텔레오퍼레이션 104 에피소드(평균 38.2초), 색상 × 팔 26/26/26/26 균등

분기 두 팔 동작은 중앙값 23.6초에 갈라짐 — 그 전까지 행동 동일

학습 ACT · SmolVLA 동일 데이터, batch 16, 80k 스텝

평가 모델당 40회 (배치 2 × 시작 위치 2 × 지시 2, 각 5회), Fisher 정확검정

▸ 왜 언어가 불리한가



- 언어로 설명되는 행동 차이는 23.6초 이후에만 존재
- 영상·관절 상태는 처음부터 끝까지 오차 감소에 기여
- 관절값을 그대로 복사만 해도 오차 6.741 → 1.555 (정책이 줄인 오차의 84%)

연구 결과 Results

▸ 단계별 성공률 (모델당 40회)

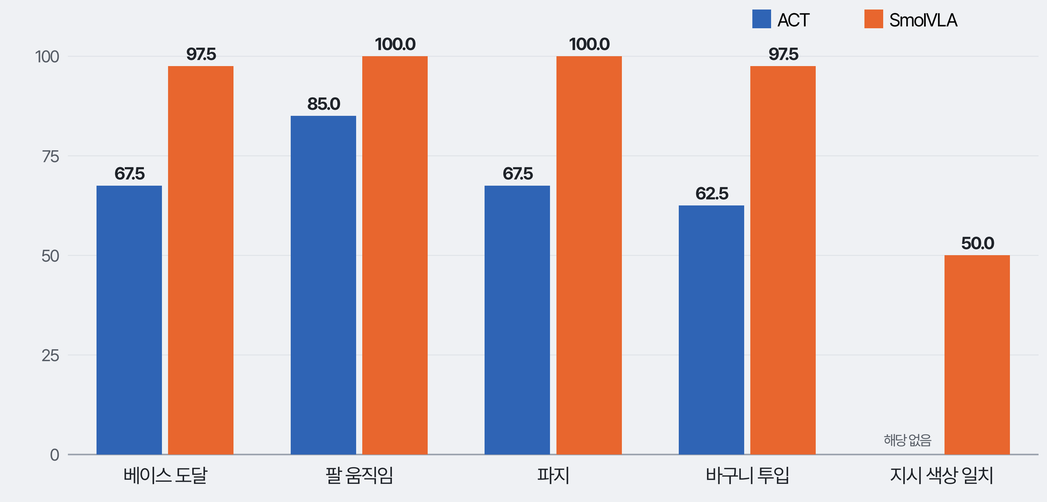


그림 4. ACT는 언어 입력을 받지 않으므로 지시 색상 일치는 SmolVLA만 해당

- SmolVLA, 조작 네 단계 모두 ACT보다 유의하게 높음 → RQ1 확인
- 그러나 지시 색상 일치는 **50.0%**에 그침
  - 8개 조건 전부 지시와 무관하게 오른쪽 주사위 파지 — 배치가 좌우 균형이라 산술적으로 50%
- ACT도 팔이 움직인 34회 중 32회(94.1%)가 오른팔

입력 민감도 분석 Input Swap

- 학습 데이터 104 에피소드에서 입력을 하나씩 교체해 예측 팔 변화 측정
- 대상: 분기 직전 312 장면 (로봇은 움직이지 않음)

▸ 입력 교체 시 예측 팔이 뒤집힌 비율 (%)

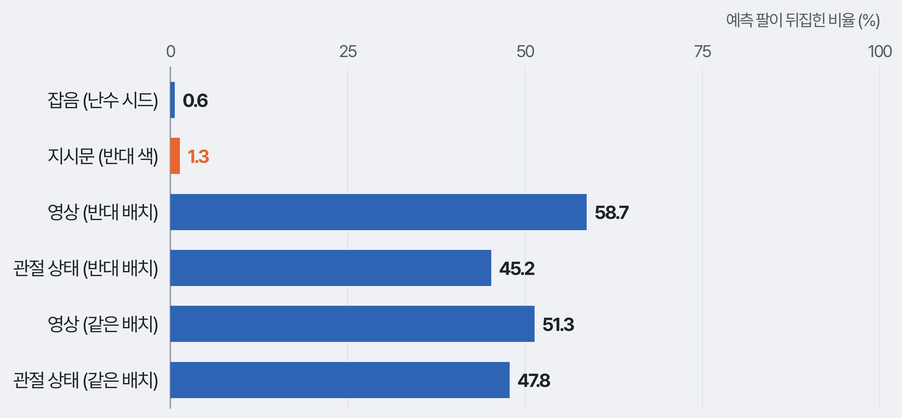


그림 5. 잡음은 난수 시드만, 나머지는 짝 에피소드에서 그 입력만 가져와 교체

바꾼 입력	정답 팔이 바뀌어야 하나	이상값	실제
잡음 (난수 시드)	아니오	0%	0.6%
지시문 (반대 색)	**예**	**100%**	**1.3%**
영상 (반대 배치)	예	100%	58.7%
관절 상태 (반대 배치)	아니오	0%	45.2%
영상 (같은 배치)	아니오	0%	51.3%
관절 상태 (같은 배치)	아니오	0%	47.8%

반대 배치 짝 = 같은 색 지시·반대 팔 / 같은 배치 짝 = 배치 동일·다른 지시. 분기 전이라 팔이 아직 움직이지 않았고(중앙값 0.1°), 관절 상태에는 주사위의 색·위치 정보가 없음

언어 기대값 100% → 실제 **1.3%**, 잡음 기준(0.6%)과 같은 수준

배치 영상 58.7% 중 배치 기여분은 7.4%p(= 58.7 − 51.3)뿐

관절 45.2% vs 47.8% — 배치와 무관, 다른 요인에 반응

전체 네 값 모두 50% 부근 — 지배적 입력 없이 하나만 바꿔도 결정이 흔들림

결론 및 시사점 Conclusion

- SmolVLA는 조작 네 단계 모두 ACT보다 유의하게 우세(RQ1) — 그러나 지시 색상 일치 50.0%, **40회 모두 오른팔** 사용(RQ2)
- 입력 교체 시 지시문 변경엔 거의 무반응, 영상·관절 상태 변경엔 크게 반응
- 배치가 같은 장면으로 바꿔도 절반이 뒤집힘 → 에피소드별 장면·자세의 미세한 차이에 의존 가능성
- 구조가 다른 두 정책이 같은 쏠림 → 특정 모델이 아닌, **행동과 관측 상태가 동일 변수로 구성되는 데이터 수집 방식**에서 비롯됨을 시사

한계 실기 평가 모델당 40회·단일 시드 / 입력 교체 분석은 학습 데이터 대상 / 단일 장면·단일 작업

향후 검증용 에피소드 분리 재학습으로 과적합 정량화 / 주사위 배치·초기 상태 다양화로 일반화 확인

참고문헌 References

[1] Y. Yu et al., "Benchmarking Vision-Language-Action Models on SO-101: Failure and Recovery Analysis," arXiv:2606.08881, 2026.

[2] Z. Fu, T. Z. Zhao, C. Finn, "Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation," CoRL, 2024.

[3] D. Emukpere, R. Deffayet, J.-M. Renders, "Robust Skills, Brittle Grounding: Diagnosing Restricted Generalization in Vision-Language Action Policies via Multi-Object Picking," arXiv:2602.24143, 2026.

[4] Y. Fang et al., "When Vision Overrides Language: Evaluating and Mitigating Counterfactual Failures in VLAs," arXiv:2602.17659, 2026.

[5] M. Shukor et al., "SmolVLA: A Vision-Language-Action Model for Affordable and Efficient Robotics," arXiv:2506.01844, 2025.

[6] T. Z. Zhao, V. Kumar, S. Levine, C. Finn, "Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware," RSS, 2023.