양팔 이동 조작 정책의 조작 성능과 언어 지시 추종의 괴리

Dissociation between Manipulation Performance and Language Instruction Following in a Bimanual Mobile Manipulation Policy

김미송*, 김송연*, 최명기*, 김현우†, 조혜경*

*한성대학교 AI응용학과 †주식회사 로보시지

1. 서론

저가형 로봇에서 VLA 정책 평가는 대부분 고정형 단팔에서 이루어졌다. SO-101 비교 연구[1]에서는 SmolVLA[2]가 ACT[3]보다 대체로 나은 조작 성능을 보였고, Mobile ALOHA[4]는 이동 베이스와 양팔을 한 정책으로 학습했지만 언어 지시는 쓰지 않았다.

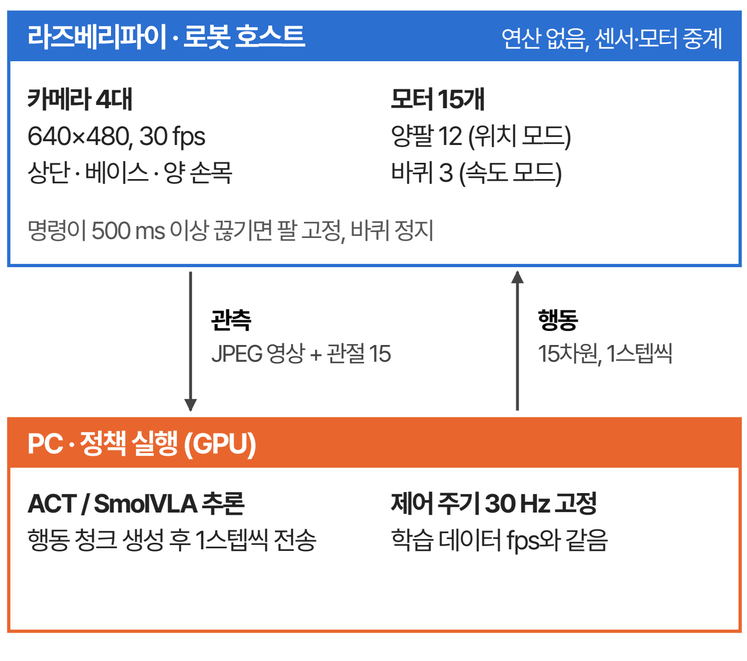
한편 조작 성공률이 높다고 해서 지시를 따른다고 볼 수 없다는 보고가 이어지고 있다[5–8]. 양팔 로봇은 목표 물체에 따라 **어느 팔을 쓸지** 골라야 하므로, 언어가 행동 결정에 들어가는지를 직접 확인할 수 있다.

> **RQ1** SmolVLA가 ACT보다 높은 조작 성능을 보이는가?
>
> **RQ2** 언어 지시에 따라 올바른 팔을 선택하는가?

또한 팔 선택 분기 전후로 언어·영상·관절 상태 입력을 하나씩 바꿔 정책이 무엇에 반응하는지 분석하였다.

2. 시스템 구성

XLeRobot[9] 기반으로 SO-ARM101 양팔과 3-옴니휠 베이스를 사용하였다. 행동·관측 상태는 양팔 관절 12개와 베이스 속도(x, y, θ) 3개의 **15차원**이고, 여기에 카메라 4대 영상이 더해진다. 학습·추론은 LeRobot[10]을 사용하였다.



유선 왕복 평균 2.8 ms (최대 9.9 ms), 손실 0%
무선 평균 812 ms 지연으로 관측이 갱신되지 않음
→ 모든 평가는 유선, 30 Hz 고정 조건에서 수행

그림 1. 분산 제어 구조 (ZMQ 5556 관측 / 5555 행동)

3. 과제 및 실험 설정

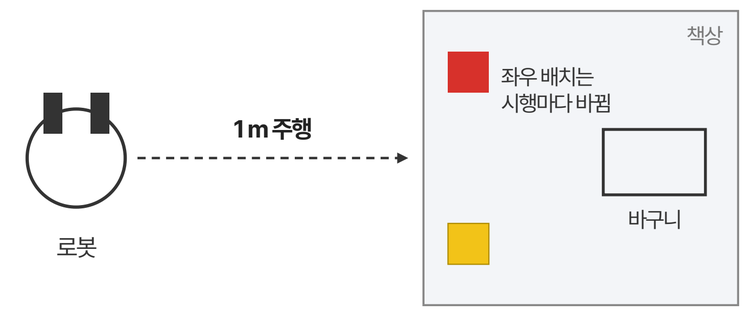


그림 2. 과제 배치 (위에서 본 모습)

로봇은 1 m 앞 책상까지 이동한 뒤 좌우에 놓인 빨강·노랑 주사위 중 **지시된 색을 그쪽 팔로** 집어 바구니에 넣는다. 지시문은 색 단어 하나만 다르고 두 주사위가 늘 함께 있으므로, 영상만으로는 대상을 정할 수 없다.

3. 과제 및 실험 설정 (계속)

- 데이터: 텔레오퍼레이션 **104 에피소드**(평균 38.2초), 색상×팔 26/26/26/26 균등
- 두 팔의 동작은 중앙값 **23.6초**에서 갈라지며, 그 전까지는 지시와 관계없이 행동이 같다
- 학습: 두 모델 모두 같은 데이터, batch 16, 80k 스텝
- 평가: 모델당 40회(배치 2 × 시작 위치 2 × 지시 2, 각 5회). 단계별로 독립 판정하고 Fisher 정확 검정·이항 검정으로 비교

4. 결과

SmolVLA는 조작 네 단계 모두에서 ACT보다 유의하게 높았다(**RQ1**). 그러나 지시 색상 일치율은 **50.0%**였다(**RQ2**). 8개 조건 전부에서 지시와 관계없이 오른쪽 주사위를 집었고, 배치가 좌우 균형이라 산술적으로 50%가 된 것이다.

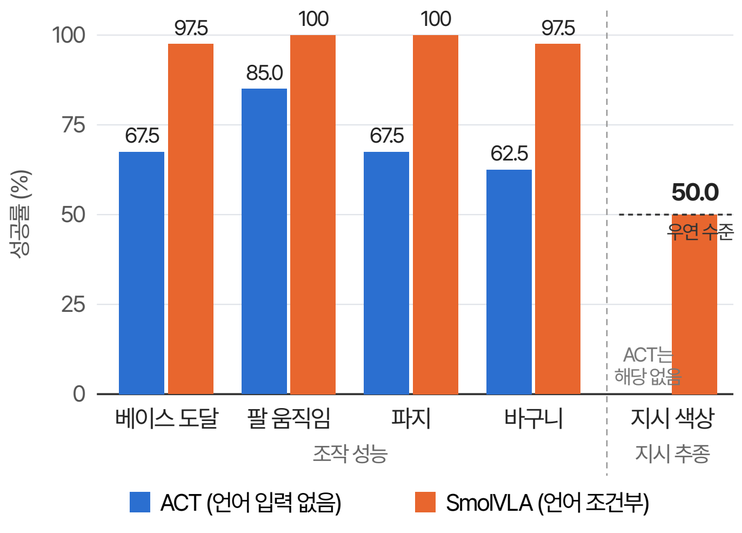


그림 3. 단계별 성공률 (모델당 40회)

표 1. 모델별 단계 성공률 (각 40회)

	ACT	SmolVLA	p
베이스 도달	67.5%	97.5%	<0.001
팔 움직임	85.0%	100%	0.026
파지	67.5%	100%	<0.001
바구니 투입	62.5%	97.5%	<0.001
지시 색상 일치	–	**50.0%**	1.0
오른팔 사용	94.1% (32/34)	**100%**	<0.001

위 네 항목은 ACT–SmolVLA 간 Fisher 정확 검정, 지시 색상 일치와 오른팔 사용은 50% 대비 이항 검정. 오른팔 사용의 분모는 팔이 움직인 시행(ACT 34회, SmolVLA 40회).

40 / 40 SmolVLA 오른팔 사용

조작은 거의 완벽했지만 "빨강"이든 "노랑"이든 같은 팔로 같은 쪽 주사위를 집었다. ACT도 94.1%가 오른팔이었다.

5. 입력 민감도 분석

학습 데이터 104 에피소드에서 입력을 하나씩 바꿔 SmolVLA가 예측하는 팔을 확인하였다. 사용한 팔의 관절이 처음 값에서 10° 이상 벗어난 첫 프레임을 **분기 시점**으로 두고, 분기 전 312장면과 후 208장면을 평가하였다. 교체 입력은 같은 색 지시이면서 주사위 배치가 반대인 짝 에피소드에서 가져왔다.

5. 입력 민감도 분석 (계속)

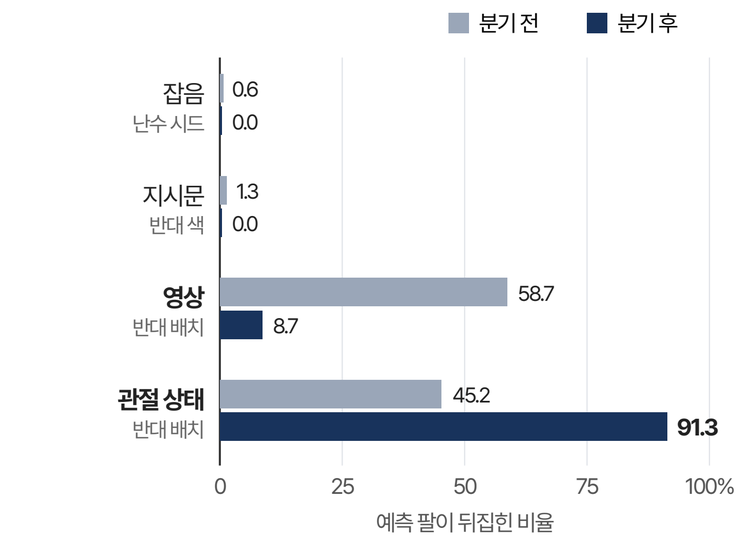


그림 4. 입력 교체 시 예측 팔 뒤집힘 (SmolVLA)

각 행은 해당 입력만 바꾼 독립 시험 (분모: 분기 전 312, 후 208장면)

지시문은 거의 무시된다

지시문만 바꾸면 출력이 달라지므로 지시문이 계산에 들어가기는 한다. 그러나 예측 팔이 바뀐 비율은 **1.3%**(4/312)로 잡음 기준(0.6%)과 비슷했다. 분기 전에는 영상과 관절 상태, 분기 후에는 관절 상태의 영향이 지배적이었다.

학습 데이터 안에서는 맞힌다

원본 입력에서 분기 전 예측 팔은 시연과 **99.7%** 일치했으나 실기에서는 오른팔만 썼다. 관절값을 그대로 복사하기만 해도 정책이 줄인 오차의 84%를 얻을 수 있어 상태 복사 문제[11]와 비슷한 구조이지만, 이것이 직접 원인인지는 이 시험만으로 판단할 수 없다.

또한 분기 1초 전부터 0.17초 전까지 사용 팔의 관절은 출발 자세 대비 중앙값 0.1°만 변했는데도 예측 팔은 99–100% 일치하였다. 주사위 배치는 같고 지시와 사용 팔만 다른 에피소드의 영상이나 관절 상태로 바꿔도 예측 팔이 각각 **51.3%**, **47.8%** 바뀌어, 정책은 주사위 배치보다 에피소드별 장면·자세의 미세한 차이에 반응했을 가능성이 있다.

6. 결론

SmolVLA는 조작 네 단계 모두 ACT보다 유의하게 높았으나 지시 색상 일치율은 50.0%였고 40회 모두 오른팔을 썼다. 조작 성능과 언어 지시 추종의 괴리[6,8]가 양팔 이동 조작에서도 나타났으며, **두 능력은 따로 평가해야 한다.**

한계 모델당 40회·단일 시드, 입력 교체 분석은 학습 데이터 대상, 단일 장면·단일 작업.
향후 짝 에피소드 일부를 빼고 재학습해 에피소드별 미세한 차이에 의존하는지 확인하고, 주사위 배치와 초기 상태를 다양화한다.

참고문헌

1. Y. Yu et al., Benchmarking VLA Models on SO-101, arXiv:2606.08881, 2026.
2. M. Shukor et al., SmolVLA, arXiv:2506.01844, 2025.
3. T. Z. Zhao et al., Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware, RSS 2023.
4. Z. Fu et al., Mobile ALOHA, CoRL 2024.
5. S. Fei et al., LIBERO-Plus, arXiv:2510.13626, 2025.
6. D. Emukpere et al., Robust Skills, Brittle Grounding, arXiv:2602.24143, 2026.
7. Y. Fang et al., When Vision Overrides Language, arXiv:2602.17659, 2026.
8. S. Jiang et al., Encoded but Not in Control, arXiv:2610.06235, 2026.
9. G. Wang, XLeRobot, GitHub, 2025.
10. R. Cadene et al., LeRobot, GitHub, 2024.
11. C. Wen et al., Fighting Copycat Agents in Behavioral Cloning, NeurIPS 2020.