양팔 이동 조작 정책의 조작 성능과 언어 지시 추종의 괴리

Dissociation between Manipulation Performance and Language Instruction Following in a Bimanual Mobile Manipulation Policy

김미송*, 김송연*, 최명기*, 김현우†, 조혜경*

*한성대학교 AI응용학과 †주식회사 로보시지

연구 배경

저가형 로봇의 VLA 정책 평가는 주로 고정형 단팔에서 이루어졌다. SO-101 비교 연구[1]에서는 SmolVLA[2]가 ACT[3]보다 대체로 나은 조작 성능을 보였고, Mobile ALOHA[4]는 이동 베이스와 양팔을 한 정책으로 학습했지만 언어 지시는 쓰지 않았다.
최근에는 조작 성공률이 높아도 언어 지시를 따른다고 볼 수 없다는 보고가 이어지고 있다[5–8].

연구 목적

양팔 로봇은 목표 물체에 따라 **어느 팔을 쓸지** 골라야 하므로, 언어 지시가 행동 결정에 반영되는지 직접 확인할 수 있다.

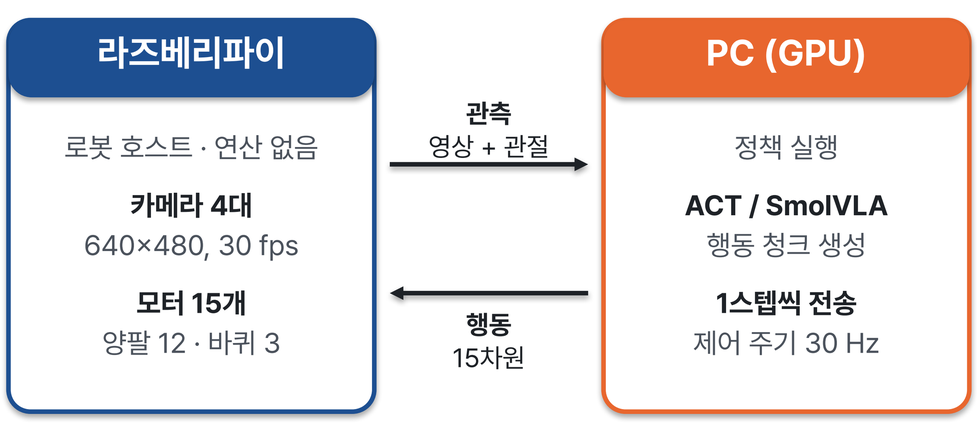
RQ1 **SmolVLA가 ACT보다 높은 조작 성능을 보이는가?**

RQ2 **언어 지시에 따라 올바른 팔을 선택하는가?**

또한 팔 선택 분기 전후로 언어·영상·관절 상태 입력을 하나씩 바꿔 정책이 무엇에 반응하는지 분석한다.

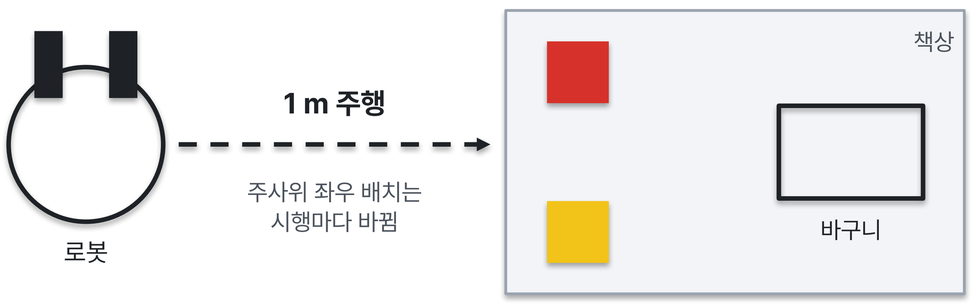
시스템 구성

XLeRobot[9] 기반 SO-ARM101 양팔과 3-옴니휠 베이스. 행동·관측 상태는 양팔 관절 12개와 베이스 속도(x, y, θ) 3개의 **15차원**이고, 관측에 카메라 4대가 더해진다. 학습·추론은 LeRobot[10]을 사용하였다.



유선 왕복 평균 2.8 ms(최대 9.9 ms), 손실 0% **무선** 평균 812 ms 지연 → 평가는 모두 유선·30 Hz 고정

과제 및 실험 설정



1 m 앞 책상까지 이동한 뒤 좌우에 놓인 주사위 중 **지시된 색을 그쪽 팔로** 집어 바구니에 넣는다. 지시문은 색 단어 하나만 다르고 두 주사위가 늘 함께 있어, 영상만으로는 대상을 정할 수 없다.

데이터

텔레오퍼레이션 **104 에피소드**(평균 38.2초), 색상×팔 26/26/26/26. 두 팔 동작은 중앙값 23.6초에서 갈라진다.

학습

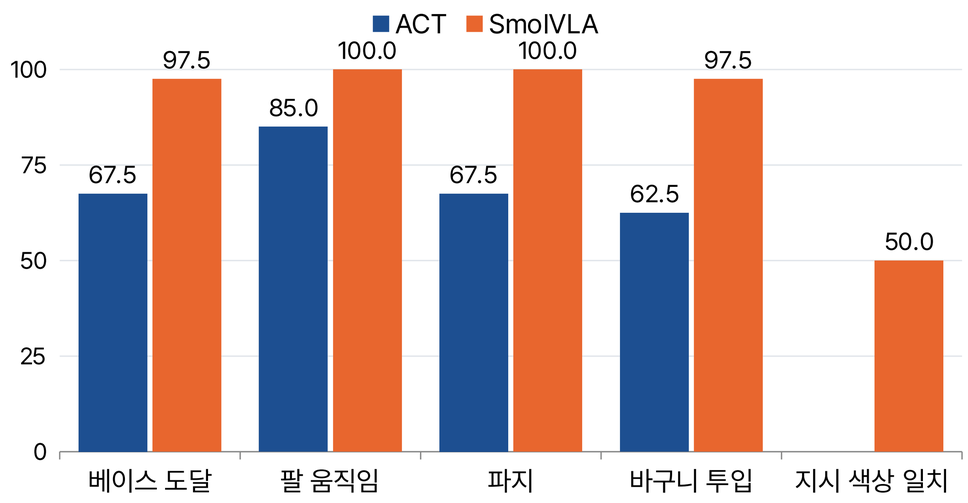
ACT·SmolVLA 같은 데이터, batch 16, 80k 스텝

평가

모델당 40회(배치 2 × 시작 위치 2 × 지시 2, 각 5회), 단계별 독립 판정, Fisher 정확 검정·이항 검정

연구 결과

▶ 단계별 성공률 (모델당 40회)



97.5% — **바구니 투입**
SmolVLA (ACT 62.5%)

50.0% — **지시 색상 일치**
우연 수준 (p = 1.0)

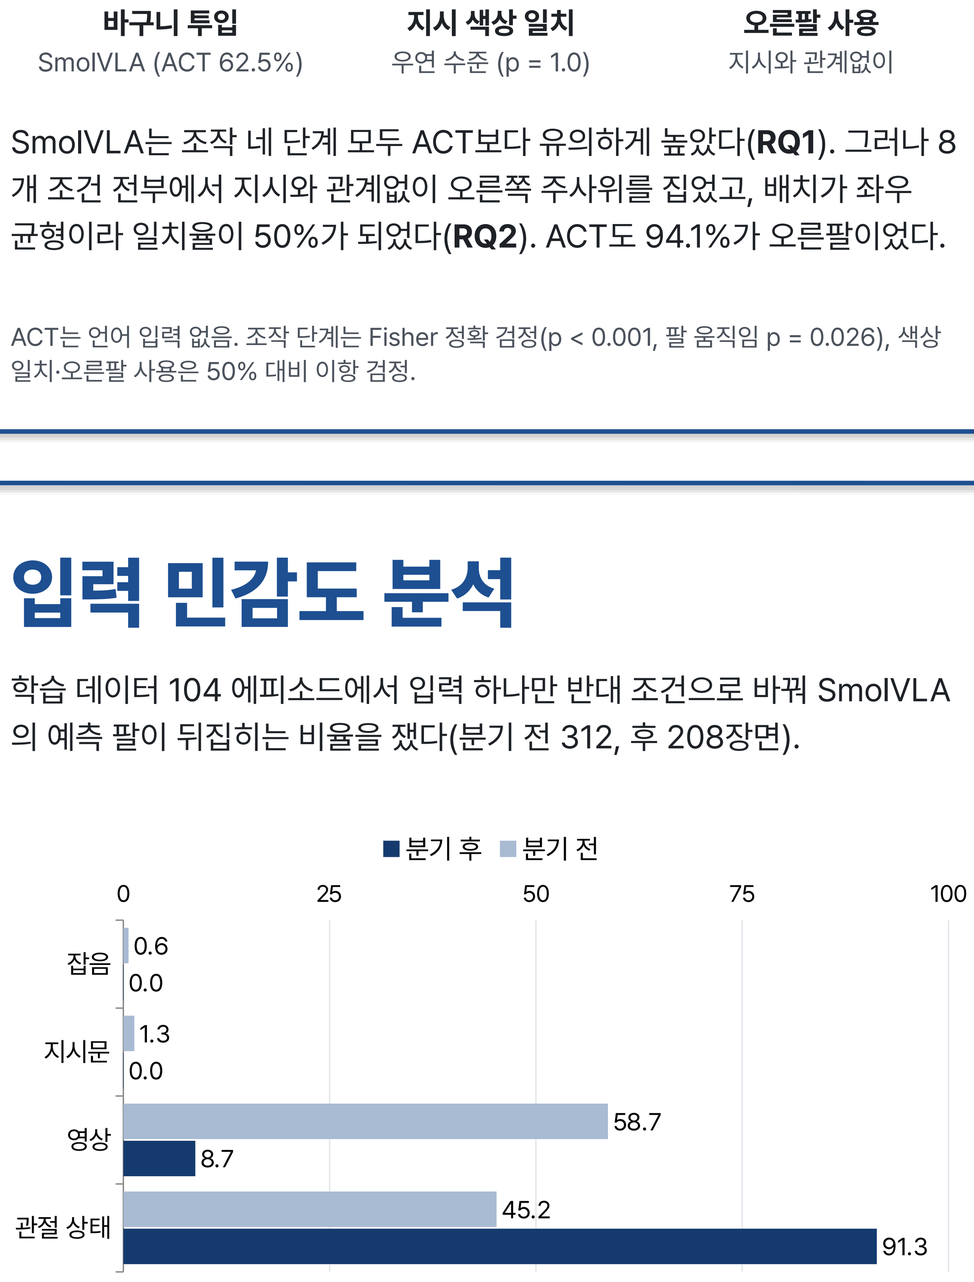
40/40 — **오른팔 사용**
지시와 관계없이

SmolVLA는 조작 네 단계 모두 ACT보다 유의하게 높았다(**RQ1**). 그러나 8개 조건 전부에서 지시와 관계없이 오른쪽 주사위를 집었고, 배치가 좌우 균형이라 일치율이 50%가 되었다(**RQ2**). ACT도 94.1%가 오른팔이었다.

ACT는 언어 입력 없음. 조작 단계는 Fisher 정확 검정($p < 0.001$, 팔 움직임 $p = 0.026$), 색상 일치·오른팔 사용은 50% 대비 이항 검정.

입력 민감도 분석

학습 데이터 104 에피소드에서 입력 하나만 반대 조건으로 바꿔 SmolVLA의 예측 팔이 뒤집히는 비율을 쟀다(분기 전 312, 후 208장면).



예측 팔이 뒤집힌 비율(%). 잡음은 난수 시드만, 나머지는 반대 색·반대 배치 입력으로 교체

지시문 예측 팔이 바뀐 비율 **1.3%**로 잡음 기준(0.6%)과 비슷. 계산에는 들어가지만 팔 선택은 바꾸지 못했다.

영상·관절 분기 전에는 영상(58.7%)과 관절 상태(45.2%), 분기 후에는 관절 상태(**91.3%**)의 영향이 지배적이었다.

일반화 학습 데이터에서는 예측 팔이 **99.7%** 맞았지만 실기에서는 오른팔만 썼다. 상태 복사 문제[11]와 비슷한 구조이다.

결론

SmolVLA는 조작 성능에서 ACT를 크게 앞섰지만, 언어 지시에 따라 팔을 고르지는 못했다. 조작 성능과 언어 지시 추종의 괴리[6,8]가 양팔 이동 조작에서도 나타났으며, **두 능력은 분리해서 평가해야 한다.**

한계 모델당 40회·단일 시드, 입력 교체 분석은 학습 데이터 대상, 단일 장면·단일 작업
향후 짝 에피소드 일부를 빼고 재학습해 미세한 장면 차이 의존 여부 확인, 주사위 배치·초기 상태 다양화

참고문헌

[1] Y. Yu et al., Benchmarking VLA Models on SO-101, arXiv:2606.08881, 2026. [2] M. Shukor et al., SmolVLA, arXiv:2506.01844, 2025. [3] T. Z. Zhao et al., Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware, RSS 2023. [4] Z. Fu et al., Mobile ALOHA, CoRL 2024. [5] S. Fei et al., LIBERO-Plus, arXiv:2510.13626, 2025. [6] D. Emukpere et al., Robust Skills, Brittle Grounding, arXiv:2602.24143, 2026. [7] Y. Fang et al., When Vision Overrides Language, arXiv:2602.17659, 2026. [8] S. Jiang et al., Encoded but Not in Control, arXiv:2610.06235, 2026. [9] G. Wang, XLeRobot, GitHub, 2025. [10] R. Cadene et al., LeRobot, GitHub, 2024. [11] C. Wen et al., Fighting Copycat Agents in Behavioral Cloning, NeurIPS 2020.